

Arquitectura de ordenadores

3-3. Aritmética III

Carlos M. Vallez Fernández carlos.vallez@u-tad.com

Nayra Déniz Benítez nayra.deniz@u-tad.com

2025-2026

Índice

1. Representación en coma flotante

3. Representación en coma flotante

- Tanto la representación en S-M como el complemento a uno y complemento a dos sirven para representar rangos de números enteros negativos y positivos centrados en el cero.
- Las representaciones vistas hasta ahora se denominan “en punto fijo”.
- Tienen un inconveniente grave, no sirven para representar cantidades muy grandes o muy pequeñas.

3. Representación en coma flotante

- Asumiendo una coma fija en una determinada posición de la cadena de bits, se pueden representar números con parte fraccionaria: 10001,01; 11000,11; 11100,10; 10101,01
 - Como hemos comentado, esta representación tiene limitaciones:
 - No puede representar números muy grandes.
 - No puede representar fracciones muy pequeñas.

3. Representación en coma flotante

- Asumiendo una coma fija en una determinada posición de la cadena de bits, se pueden representar números con parte fraccionaria: 10001,01; 11000,11; 11100,10; 10101,01
 - Como hemos comentado, esta representación tiene limitaciones:
 - No puede representar números muy grandes.
 - No puede representar fracciones muy pequeñas.
- Para solucionarlo se recurre a la anotación en punto flotante, que no es otra cosa que la notación científica en base dos. Las representaciones en **coma flotante** permiten representar números positivos y negativos con parte fraccionaria sin estas limitaciones.

3. Representación en coma flotante

Vamos a recordar qué es eso de notación científica con dos ejemplos:

- N° de Avogadro: 6.02×10^{23}
 - Donde 6.02 es la mantisa, 10 es la base y 23 es el exponente.
- Constante de Planck: $6,62 \times 10^{-34}$

Estas dos constantes aparecen normalizadas, es decir, hay una y solo una cifra significativa antes del punto decimal.

En punto flotante se usa la base 2. tiene la propiedad de que si la cantidad está normalizada. la cifra que hay antes del punto es siempre 1.

Ejemplo: 0.28125 en base 10 equivale a 0,01001 en base 2. Y para expresarlo en coma flotante pondríamos $1,001 \times 2^{-2}$.

3. Representación en coma flotante

La representación en **coma flotante** más usual tiene el siguiente formato:



El formato sigue la misma técnica que la **notación científica**:

- en decimal: $\pm M \times B^{\text{Exp}} = +3 \cdot 10^{-3} = 0,003$
- en binario: $\pm M \times B^{\text{Exp}} = +1 \cdot 2^{-3} = 0,125$

Donde +/- es el signo, M la magnitud, Exp el exponente y B la base (también llamada radix).

La **base** siempre es fija (en decimal $B = 10$, en binario $B = 2$), por lo que **no se representa**.


El resto de partes se pueden codificar mediante diferentes sistemas de representación.

3.1 Repres. coma flotante S-M

En este apartado vamos a ver cómo se representan cada uno de los campos de la coma flotante (signo, exponente y mantisa) en formato S-M.

3.1 Repres. coma flotante S-M

Signo: se representa con un bit. 1 es negativo y 0 es positivo.



En este ejemplo se emplean q bits para el exponente y P = 5 para la mantisa.

3.1 Repres. coma flotante S-M

Magnitud:

Las **magnitudes** se deben presentar **normalizadas**.

La coma se puede situar entre cualquier par de bits o en alguno de los extremos. En una magnitud normalizada, se sobreentiende que **la coma se sitúa a la izquierda del bit más significativo** (el más a la izquierda).

En S-M, una magnitud está normalizada si el bit que acompaña al bit de signo es igual a 1.

S-M	Valor	Normalizado
1 01010	- 0,01010	NO
0 01010	+ 0,01010	NO
1 10101	- 0,10101	SÍ
0 10101	+ 0,10101	SÍ

3.1 Repres. coma flotante S-M

Magnitud:

Como el **bit más significativo** de la magnitud siempre debe ser 1, nunca se representa, sino que se entiende que está **implícito**.

.

S-M codificado	S-M representado
0 01011	0 101011
1 01011	1 101011

1 + 5 bits

1 + 6 bits

Se gana un bit

3.1 Repres. coma flotante S-M

Magnitud:

Para un valor de $p = 5$ bits, el rango de representación con normalización y bit implícito es el siguiente:

		S-M	Valor
Negativos	Mayor	1 111111	$-(1 - 2^{-6})$
	Menor	1 100000	-2^{-1}
Positivos	Menor	0 100000	2^{-1}
	Mayor	0 111111	$(1 - 2^{-6})$

Bits implícitos

3.1 Repres. coma flotante S-M

Exponente:

Tiene q bits para el exponente. Ejemplo: $p = 5$ y $q = 4$



- Está codificado en **representación sesgada**, también llamada **exceso M**:
- El exponente puede ser negativo, pero el signo no se codifica en ningún bit.
- El valor codificado en el exponente es igual al valor en binario más un valor fijo llamado sesgo. El valor típico del sesgo es $2^{q-1}-1$. En el ejemplo, el sesgo de 4 es: 7
- El sesgo permite que se codifiquen exponentes negativos. Con $q = 4$ se puede codificar desde 0000 hasta 1111 en binario puro

3.1 Repres. coma flotante S-M

Exponente:

Codificado	Codificado	Exponente
0000	0	-7
1111	15	8

SESGO= PESO BIT MAS SIGNIFICATIVO – 1

COD=EXP+SESGO

EXP=COD-SESGO

- Representación sesgada también es llamada **exceso M**.
- Para un valor genérico de q bits, se tiene que el rango del exponente en representación sesgada es: $[-(2^{q-1} - 1), 2^{q-1}]$:

$$[-2^{q-1}-1, 2^{q-1}]$$

q	Rango en binario puro	Rango con sesgo
4	[0, 15]	[-7, 8]
8	[0, 255]	[-127, 128]
q	$[0, 2^q - 1]$	$[-2^{q-1} + 1, 2^{q-1}]$

3.1 Repres. coma flotante S-M

Veamos un primer ejemplo completo negativo:

representar -0,28125 en base 10 cómo sería en coma flotante y aprovechamos para recordar cómo pasar de coma flotante a decimal de nuevo:

Diagram of the IEEE 754 single-precision floating-point format (32 bits):

1	0	0	1	0	0	1	0
---	---	---	---	---	---	---	---

Signo = -1

Exponente = 001 - sesgo = 1 - 3 = -2

Mantisa = $(1 + magnitud)_2 = 10010$

Número binario = $-001001 = -\frac{1}{4} + \frac{1}{32} = -0.28125$

$$0,28125 = 1/4 + 1/32 = 0,25 + 0,03125$$

$$\text{EXP} = \text{COD} - \text{SESGO} \Rightarrow \text{COD} = \text{EXP} + \text{SESGO} = -2 + 3 = 1 \Rightarrow 001$$

3.1 Repres. coma flotante S-M


Magnitud:

Dicho de otra forma, el primer bit de la mantisa se suprime, se dice que va “implícito” y se gana un bit de precisión. En nuestro ejemplo:

0,28125 en decimal se representaría como 0 001 0010. Donde el primer 0 indica que es positivo, el 001 es el exponente que explicaremos seguidamente y el 0010 corresponde al 1001 al cual se ha quitado el primer 1 por considerarlo implícito (por tanto no se almacena) y a su vez hemos ganado más precisión con un cero más al final

3.1 Repres. coma flotante S-M

- Ejemplo: $p = 5$, $q = 4$ y 1 bit de signo. Magnitud normalizada y con bit implícito.



- Rango de la representación en coma flotante:

		Coma flotante			Valor
		Signo	Exp sesgo 7	Magnitud normalizada con bit implícito	
Negativos	Mayor	1	1111	111111	$-(1 - 2^{-6}) \cdot 2^8$
	Menor	1	0000	100000	$-2^{-1} \cdot 2^{-7}$
Positivos	Menor	0	0000	100000	$2^{-1} \cdot 2^{-7}$
	Mayor	0	1111	111111	$(1 - 2^{-6}) \cdot 2^8$

3.1 Repres. coma flotante S-M

- Rango del exponente (otra forma de calcularlo como vimos): $15 - 7 = 8$ y $0 - 7 = -7$ o simplemente aplicando: $[-2^{q-1} - 1, 2^{q-1}] = [-2^{4-1} - 1, 2^{4-1}] = [-2^3 - 1, 2^3] = [-7, 8]$
- Para hallar el número mayor: tomamos el mayor exponente posible 2^8 por el número más grande que es $0,111111$. Una forma más cómoda de expresar ese número es poner $(1 - 2^{-6})$ el cual multiplicamos por el exponente y no da $(1 - 2^{-6}) * 2^8$. Aplicaremos
signo en función de que queramos hallar el mayor positivo o negativo.
- Para hallar el menor valor conseguimos el menor exponente 2^{-7} . La mantisa más pequeña es $0,100000$ que equivale a 2^{-1} . Lo multiplicamos por el exponente y nos queda $2^{-1} * 2^{-7}$ con el signo que corresponda en función de si queremos el menor negativo o el menor positivo.

3.1 Repres. coma flotante S-M

Como características de la representación en coma flotante hay que comentar:

- No se representa el 0.
- No se representa un intervalo abierto alrededor del 0

- Rango de la representación en coma flotante:

		Coma flotante			Valor
		Signo	Exp sesgo 7	Magnitud normalizada con bit implícito	
Negativos	Mayor	1	1111	111111	$-(1 - 2^{-6}) \cdot 2^8$
	Menor	1	0000	100000	$-2^{-1} \cdot 2^{-7}$
Positivos	Menor	0	0000	100000	$2^{-1} \cdot 2^{-7}$
	Mayor	0	1111	111111	$(1 - 2^{-6}) \cdot 2^8$

- No se representa el 0.
- No se representa un intervalo abierto alrededor del 0: $(-2^{-1} \cdot 2^{-7}, 2^{-1} \cdot 2^{-7})$



Como hemos podido comprobar el 0 no puede representarse en pura lógica. Para evitarlo vamos a ver cómo se resuelve con los estándares del IEEE.

3.2 IEEE 754

IEEE 754 es un estándar de representación de punto flotante de precisión simple con 32 bits. se utiliza 1 bit para el signo, 8 bits para el exponente y 23 para la magnitud.

El sesgo vale $2^7-1 = 127$

3.2 IEEE 754

La siguiente imagen resume sus características. Conviene prestar especial atención a los valores especiales que resumidos son:

- Exponente 0 y Mantisa 0 = Número 0 (ahora sí que lo podemos representar +0y -0)
- Exponente 255 y Mantisa 0 = + o – menos infinito
- Exponente 255 y Mantisa distinto 0 = NaN not a number)

3.2 IEEE 754

- Precisión simple (Float)



- Exponente en exceso 127 $\text{Exp} = (\text{valor} - 127)$
 - Exp 0 y Mantisa 0. Numero 0
 - Expo 0 y Mantisa distinta de 0. Número desnormalizados 0, pero con exponente -126 no -127
 - Exp 255 y Mantisa 0. + Infinito y -Infinito
 - Exp 255 y Mantisa distinto de 0. Not a number (NaNs)
 - Exp 1 a 254 Números normalizados con Exponente [-126,127]
- Mantisa normalizada a 1, y bit implícito

3.2 IEEE 754

En lo referente a rango de representación podemos observarlo en la siguiente imagen:

- Precisión simple (Float)



- Máximo positivo representable $(2 - 2^{-23}) \times 2^{127} = 3.402823 \times 10^{38}$
- Mínimo positivo normalizado $(1,) \times 2^{-126} = 1.18 \times 10^{-38}$
- Máximo positivo no normalizado $(1 - 2^{-23}) \times 2^{-126} = 1.175 \times 10^{-38}$
- Mínimo positivo no normalizado $(2^{-23}) \times 2^{-126} = 1.4 \times 10^{-45}$
- Dos representaciones para el 0 (-0 y +0)

3.2 IEEE 754

En lo referente a rango de representación podemos observarlo en la siguiente imagen:

- Precisión simple (Float)



- Máximo positivo representable $(2-2^{-23}) \times 2^{127} = 3.402823 \times 10^{38}$
- Mínimo positivo normalizado $(1,) \times 2^{-126} = 1.18 \times 10^{-38}$
- Máximo positivo no normalizado $(1 - 2^{-23}) \times 2^{-126} = 1.175 \times 10^{-38}$
- Mínimo positivo no normalizado $(2^{-23}) \times 2^{-126} = 1.4 \times 10^{-45}$
- Dos representaciones para el 0 (-0 y +0)

EXPONENTE	MANTISA	Numero
0	0	+0 [signo (0)] - 0 [signo (1)]
255	0	+ infinito [signo (0)] - infinito [signo (1)]
255	≠0	<u>NaN</u> (Not a Number) (ej. 0/0, √ - 1)
1 a 254 (Sin codificar -126 a 127)	Cualquier valor	Número normalizados 1, ----- (bit implícito) (Número normales)
0 (Sin codificar valor fijo de exponente -126)	Cualquier valor ≠0	Número (des)normalizados 0, ----- (no hay bit implícito) (Número muy pequeños) < 1×2^{-126}

3.2 IEEE 754

Adicionalmente al estándar visto el IEEE ofrece otro con precisión doble y 64 bits, el IEEE 754 (64 bits). En la siguiente imagen se pueden ver sus características:

- Precisión doble (Double)



- Máximo positivo representable $(1+(1-2^{-52})) \times 2^{1023} = 1.79769 \times 10^{308}$
- Mínimo positivo normalizado $(1,) \times 2^{-1022} = 2.22507 \times 10^{-308}$
- Mínimo positivo no normalizado $(2^{-52}) \times 2^{-1022} = 4.94065 \times 10^{-324}$
- Dos representaciones para el 0 (-0 y +0)