

Práctica 1: Programación en R

Probabilidad y Estadística

Introducción

El objetivo de esta práctica es realizar un estudio muy superficial de modelos de regresión simple. Para ello, necesitaremos un conjunto de datos (*dataset*) sobre el que hacer el estudio. En la primera parte de la práctica, cargaremos dicho *dataset* y realizaremos una exploración estadística de ellos. En la segunda parte, realizaremos un estudio de regresión más específico.

Información del *dataset*

El dataset elegido es “*Boston Housing*”. Consiste en un *dataset* público con información de viviendas en Boston. En concreto, el *dataset* contiene las siguientes columnas:

- **CRIM**: Per capita crime rate by town
- **ZN**: Proportion of residential land zoned for lots over 25,000 sq. ft
- **INDUS**: Proportion of non-retail business acres per town
- **CHAS**: Charles River dummy variable (= 1 if tract bounds river; 0 otherwise)
- **NOX**: Nitric oxide concentration (parts per 10 million)
- **RM**: Average number of rooms per dwelling
- **AGE**: Proportion of owner-occupied units built prior to 1940
- **DIS**: Weighted distances to five Boston employment centers
- **RAD**: Index of accessibility to radial highways
- **TAX**: Full-value property tax rate per \$10,000
- **PTRATIO**: Pupil-teacher ratio by town
- **B**: $1000(B_k - 0.63)$?, where B_k is the proportion of [people of African American descent] by town
- **LSTAT**: Percentage of lower status of the population
- **MEDV**: Median value of owner-occupied homes in \$1000s“

El *dataset* lo cargaremos en R mediante la instalación de un paquete y su posterior importación:

```
require("mlbench")
```

```
## Loading required package: mlbench
```

```
library(mlbench)
```

Ya cargado en R, procedemos a guardar el *dataset* en la variable `housing` para que realicéis el resto de la práctica sobre ella:

```
data("BostonHousing")  
housing <- BostonHousing
```

Información de la práctica.

- La práctica se calificará sobre 10 puntos.
- La práctica se resuelve sobre este mismo código.
- Antes de entregarlo, habrá que cambiar el nombre del fichero, sustituyendo *nombre1* y *apellido1* por los propios del alumno.
- Si el alumno considera relevante la instalación de alguna librería extra que pueda mostrar mejores resultados o gráficos, es libre para hacerlo. Puntuará más si se realiza un trabajo óptimo en esta parte.
- Sobre todo en la parte final (regresión), puntuará más aquellos comentarios del alumno que muestren haber investigado el significado de todos los análisis realizados.
- Si el alumno se encuentra con errores durante la ejecución del código, tiene que aprender a lidiar con ellos como futuro ingeniero informático.
- Es recomendable consultar los diferentes comandos, así como nuevos comandos y librerías, a través de google, el cual os llevará a paginas web adecuadas de programación en R.

1) Análisis exploratorio inicial:

Se pide utilizar los comandos `str`, `head`, `dim`, `summary` sobre `housing` para explorar distribución inicial de los datos en el *dataset*.

```
# CODIGO DEL ALUMNO
```

```
str(housing)
```

```
## 'data.frame': 506 obs. of 14 variables:
## $ crim : num 0.00632 0.02731 0.02729 0.03237 0.06905 ...
## $ zn : num 18 0 0 0 0 0 12.5 12.5 12.5 12.5 ...
## $ indus : num 2.31 7.07 7.07 2.18 2.18 2.18 7.87 7.87 7.87 7.87 ...
## $ chas : Factor w/ 2 levels "0","1": 1 1 1 1 1 1 1 1 1 1 ...
## $ nox : num 0.538 0.469 0.469 0.458 0.458 0.458 0.524 0.524 0.524 0.524 ...
## $ rm : num 6.58 6.42 7.18 7 7.15 ...
## $ age : num 65.2 78.9 61.1 45.8 54.2 58.7 66.6 96.1 100 85.9 ...
## $ dis : num 4.09 4.97 4.97 6.06 6.06 ...
## $ rad : num 1 2 2 3 3 3 5 5 5 5 ...
## $ tax : num 296 242 242 222 222 222 311 311 311 311 ...
## $ ptratio: num 15.3 17.8 17.8 18.7 18.7 18.7 15.2 15.2 15.2 15.2 ...
## $ b : num 397 397 393 395 397 ...
## $ lstat : num 4.98 9.14 4.03 2.94 5.33 ...
## $ medv : num 24 21.6 34.7 33.4 36.2 28.7 22.9 27.1 16.5 18.9 ...
```

```
head(housing)
```

```
##      crim zn indus chas   nox    rm  age    dis rad tax ptratio    b lstat
## 1 0.00632 18  2.31    0 0.538 6.575 65.2 4.0900   1 296    15.3 396.90 4.98
## 2 0.02731  0  7.07    0 0.469 6.421 78.9 4.9671   2 242    17.8 396.90 9.14
## 3 0.02729  0  7.07    0 0.469 7.185 61.1 4.9671   2 242    17.8 392.83 4.03
## 4 0.03237  0  2.18    0 0.458 6.998 45.8 6.0622   3 222    18.7 394.63 2.94
## 5 0.06905  0  2.18    0 0.458 7.147 54.2 6.0622   3 222    18.7 396.90 5.33
## 6 0.02985  0  2.18    0 0.458 6.430 58.7 6.0622   3 222    18.7 394.12 5.21
##   medv
## 1 24.0
## 2 21.6
## 3 34.7
```

```
## 4 33.4
## 5 36.2
## 6 28.7
```

```
dim(housing)
```

```
## [1] 506 14
```

```
summary(housing)
```

```
##      crim              zn          indus      chas          nox
## Min.   : 0.00632   Min.    : 0.00   Min.    : 0.46   0:471   Min.    :0.3850
## 1st Qu.: 0.08205   1st Qu.: 0.00   1st Qu.: 5.19   1: 35   1st Qu.:0.4490
## Median : 0.25651   Median : 0.00   Median : 9.69           Median :0.5380
## Mean   : 3.61352   Mean    : 11.36   Mean    :11.14           Mean    :0.5547
## 3rd Qu.: 3.67708   3rd Qu.: 12.50   3rd Qu.:18.10           3rd Qu.:0.6240
## Max.   :88.97620   Max.    :100.00   Max.    :27.74           Max.    :0.8710
##      rm          age          dis          rad
## Min.   :3.561   Min.    : 2.90   Min.    : 1.130   Min.    : 1.000
## 1st Qu.:5.886   1st Qu.: 45.02   1st Qu.: 2.100   1st Qu.: 4.000
## Median :6.208   Median : 77.50   Median : 3.207   Median : 5.000
## Mean   :6.285   Mean    : 68.57   Mean    : 3.795   Mean    : 9.549
## 3rd Qu.:6.623   3rd Qu.: 94.08   3rd Qu.: 5.188   3rd Qu.:24.000
## Max.   :8.780   Max.    :100.00   Max.    :12.127   Max.    :24.000
##      tax          ptratio          b          lstat
## Min.   :187.0   Min.    :12.60   Min.    : 0.32   Min.    : 1.73
## 1st Qu.:279.0   1st Qu.:17.40   1st Qu.:375.38   1st Qu.: 6.95
## Median :330.0   Median :19.05   Median :391.44   Median :11.36
## Mean   :408.2   Mean    :18.46   Mean    :356.67   Mean    :12.65
## 3rd Qu.:666.0   3rd Qu.:20.20   3rd Qu.:396.23   3rd Qu.:16.95
## Max.   :711.0   Max.    :22.00   Max.    :396.90   Max.    :37.97
##      medv
## Min.    : 5.00
## 1st Qu.:17.02
## Median :21.20
## Mean    :22.53
## 3rd Qu.:25.00
## Max.    :50.00
```

Comentarios del alumno (máximo 100 palabras):

```
# TEXTO DEL ALUMNO
```

Comando str:

EL comando str nos permite el contenido de cada una de las variables que estamos estudiando. Este lo imprime en el formato: nombre_variable: datos.

Comando head:

Tras la utilización de este comando, podemos mostrar los datos como formato tabla y elegir el numero de filas a mostrar.
Por defecto, muestra solo 6 filas.

Comando dim:

Este comando nos muestra las dimensiones de nuestro set de datos.
En este caso nos dice que hay 506 filas y 14 columnas.
Las columnas corresponden a las variables de estudio y las filas a
el numero de datos que hay sobre cada variable.

Comando summary:

El comando summary nos ofrece varias medidas estadísticas para analizar
los datos de cada variable. Estas medidas son: Valor Mínimo, Primer Cuartil,
Mediana, Media, Tercer Cuartil y Valor Máximo.


2) Análisis exploratorio de la variable objetivo:

En esta práctica, trataremos de predecir el valor del precio medio de la vivienda MEDV. Para ello, primero exploraremos la distribución de sus datos. Se pide dibujar un histograma, calcular asimetría y apuntamiento de MEDV. Se pide dibujar un boxplot, calcular los cuartiles y los percentiles 10-90 sobre MEDV. Se pide describir los elementos más importantes de ambas gráficas.


```
# CODIGO DEL ALUMNO
#install.packages("moments")
library(moments) #Libreria necesaria para calcular asimetria y apuntamiento

hist(housing$medv,
      main = "Histograma del valor medio de las vivienda ocupadas por su dueño",
      xlab = "Valor Medio en $1000",
      ylab = "Frecuencia",
      col = "lightblue",
      breaks = 30) #Histograma de MEDV
```

Histograma del valor medio de las vivienda ocupadas por su dueño



```
boxplot(housing$medv, horizontal = TRUE)
```



```
quantile(housing$medv, probs = c(0.1,0.25,0.5,0.75,0.9))
```

```
##      10%      25%      50%      75%      90%
## 12.750 17.025 21.200 25.000 34.800
```

```
skewness(housing$medv) #Asimetria de Fischer
```

```
## [1] 1.104811
```

```
kurtosis(housing$medv)
```

```
## [1] 4.468629
```

Comentarios del alumno (máximo 100 palabras):

TEXTO DEL ALUMNO

Gracias a el histograma, podemos encontrar la clase modal siendo este el rango de valores mas frecuente. Se observa que valor medio mas frecuente es entre los 20 mil y 22 mil dolares ya que es la columna mas alta.

Tenemos una simetria de 1.10.

Esta simetria es mayor que 0 asi que el valor medio de las viviendas ocupadas desciende mas lentamente por la derecha.

Tenemos un apuntamiento de 4.46.

Al ser mayor que 3, tenemos un apuntamiento platocurtico y es menos apuntada que la distribución normal

El boxplot nos enseña los 3 cuartiles y un minimos y maximo relativos a estos para definir valores atipicos. Podemos apreciar que hay una gran cantidad de valores atipicos por la derecha para el valor medio de las viviendas ocupadas lo que nos puede indicar que estas medidas no son tan fiables ya que estos valores alteran los resultados de por ejemplo la media.

P10 = 12.75 P90 = 34.8

Q1 = 17.025 Q2 = 21.2 Q3 = 25 IQR = 7,975

3) Correlación entre variables:

Lo primero es que hay que tener en cuenta solo las variables cuantitativas. Se recomienda calcular la matriz de correlaciones de las variables cuantitativas con el comando `cor`. Además se pide utilizar el comando `corrplot` de la librería `corrplot`, y la librería `RColorBrewer` (que posiblemente tengais que instalar) para mostrar graficamente las correlaciones entre todas las variables cuantitativas. Se pide describir los elementos de la gráfica que aportan mayor información.

```
# CODIGO DEL ALUMNO
#install.packages("corrplot")
library(corrplot)
```

```
## corrplot 0.95 loaded
```


```
#is.numeric --> Comprueba que las variables sean numericas(cuantitativas)
vars_cuantitativas <- housing[,sapply(housing, is.numeric)]

matriz_correlacion <- cor(vars_cuantitativas)
matriz_correlacion
```

```
##          crim          zn          indus          nox          rm          age
## crim      1.0000000 -0.2004692  0.4065834  0.4209717 -0.2192467  0.3527343
## zn        -0.2004692  1.0000000 -0.5338282 -0.5166037  0.3119906 -0.5695373
## indus      0.4065834 -0.5338282  1.0000000  0.7636514 -0.3916759  0.6447785
## nox        0.4209717 -0.5166037  0.7636514  1.0000000 -0.3021882  0.7314701
## rm         -0.2192467  0.3119906 -0.3916759 -0.3021882  1.0000000 -0.2402649
## age        0.3527343 -0.5695373  0.6447785  0.7314701 -0.2402649  1.0000000
## dis        -0.3796701  0.6644082 -0.7080270 -0.7692301  0.2052462 -0.7478805
## rad         0.6255051 -0.3119478  0.5951293  0.6114406 -0.2098467  0.4560225
## tax         0.5827643 -0.3145633  0.7207602  0.6680232 -0.2920478  0.5064556
## ptratio    0.2899456 -0.3916785  0.3832476  0.1889327 -0.3555015  0.2615150
## b          -0.3850639  0.1755203 -0.3569765 -0.3800506  0.1280686 -0.2735340
## lstat      0.4556215 -0.4129946  0.6037997  0.5908789 -0.6138083  0.6023385
## medv       -0.3883046  0.3604453 -0.4837252 -0.4273208  0.6953599 -0.3769546
##          dis          rad          tax          ptratio          b          lstat
## crim      -0.3796701  0.6255051  0.5827643  0.2899456 -0.3850639  0.4556215
## zn         0.6644082 -0.3119478 -0.3145633 -0.3916785  0.1755203 -0.4129946
## indus      -0.7080270  0.5951293  0.7207602  0.3832476 -0.3569765  0.6037997
```

```
## nox      -0.7692301  0.6114406  0.6680232  0.1889327 -0.3800506  0.5908789
## rm       0.2052462 -0.2098467 -0.2920478 -0.3555015  0.1280686 -0.6138083
## age      -0.7478805  0.4560225  0.5064556  0.2615150 -0.2735340  0.6023385
## dis      1.0000000 -0.4945879 -0.5344316 -0.2324705  0.2915117 -0.4969958
## rad      -0.4945879  1.0000000  0.9102282  0.4647412 -0.4444128  0.4886763
## tax      -0.5344316  0.9102282  1.0000000  0.4608530 -0.4418080  0.5439934
## ptratio  -0.2324705  0.4647412  0.4608530  1.0000000 -0.1773833  0.3740443
## b        0.2915117 -0.4444128 -0.4418080 -0.1773833  1.0000000 -0.3660869
## lstat    -0.4969958  0.4886763  0.5439934  0.3740443 -0.3660869  1.0000000
## medv     0.2499287 -0.3816262 -0.4685359 -0.5077867  0.3334608 -0.7376627
##          medv
## crim     -0.3883046
## zn        0.3604453
## indus     -0.4837252
## nox       -0.4273208
## rm        0.6953599
## age       -0.3769546
## dis       0.2499287
## rad       -0.3816262
## tax       -0.4685359
## ptratio  -0.5077867
## b         0.3334608
## lstat     -0.7376627
## medv      1.0000000
```

```
corrplot(matriz_correlacion, type = "lower", method = "pie")
```



Comentarios del alumno (máximo 100 palabras):

TEXTO DEL ALUMNO

El comando `cor` es el que permite la creación de la matriz de correlación y `corrplot` nos permite visualizar con intensidades de color las correlaciones. Cuanto mas intenso es el color, mayor es la correlación. Las correlaciones positivas se muestran tonos de azul y las negativas en rojo. También, gracias al atributo de `method = pie`, podemos observar la correlación viendo como de relleno esta el círculo. A mayor correlación, mas relleno esta el círculo.

Podemos ver que por ejemplo, hay una gran interdependencia lineal negativa entre el valor medio de las viviendas ocupadas por sus dueños y el porcentaje de personas de clase social baja. Con esta información descubrimos que a menor porcentaje de personas de clase baja, mayor va a ser el valor medio de la vivienda debido a la correlación negativa.

Por otra parte, hay una correlación positiva fuerte entre el índice de accesibilidad a carreteras radiales y la tasa impositiva del valor completo de la propiedad. Esto se refiere a que un incremento de la tasa impositiva equivale a un aumento en el índice de acceso a carreteras radiales.

4) Regresiones lineales simples:

Se pide Regresiones lineales simples: Se pide escoger cuatro variables independientes (a vuestro juicio, las mejores) y realizar cuatro regresiones simples con cada una de ellas sobre la variable dependiente MEDV. Se pide dibujar los *scatterplots* de cada variable independiente con MEDV y la recta de regresión resultante sobre cada *scatterplot*, para ello habrá que instalar la librería `ggplot2`. Describir brevemente el resultado de este análisis.

CODIGO DEL ALUMNO

```
#install.packages("ggplot2")
```


```
library(ggplot2)
```

```
#se --> Elimina banda de error
```

```
ggplot(housing, aes(x = rm, y = medv)) +  
  geom_point(color = "blue") +  
  labs(title = " Precio Medio sobre el Numero de Habitaciones") +  
  geom_smooth(method = "lm", color = "red", se = FALSE)
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```


Precio Medio sobre el Numero de Habitaciones



```
ggplot(housing, aes(x = lstat, y = medv)) +  
  geom_point(color = "red") +  
  labs(title = "Precio Medio sobre el Porcentage de personas de clase baja") +  
  geom_smooth(method = "lm", se = FALSE)
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```


Precio Medio sobre el Porcentage de personas de clase baja



```
ggplot(housing, aes(x = ptratio, y = medv)) +  
  geom_point(color = "orange") +  
  labs(title = "Precio Medio sobre el Proporcion Alumno-Profesor") +  
  geom_smooth(method = "lm", se = FALSE)
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```


Precio Medio sobre el Proporción Alumno–Profesor



```
ggplot(housing, aes(x = dis, y = medv)) +  
  geom_point(color = "purple") +  
  labs(title = "Precio Medio sobre el Distancia a Centros de Empleo") +  
  geom_smooth(method = "lm", se = FALSE)
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```

Precio Medio sobre el Distancia a Centros de Empleo



Comentarios del alumno (máximo 100 palabras):

TEXTO DEL ALUMNO

Se han escogido las siguientes variables debido a que cada una muestra un tipo de correlación distinta respecto al precio medio de la vivienda.

Si analizamos el número de habitaciones promedio en una vivienda (`rm`), podemos ver que hay una correlación positiva fuerte ya que todos los puntos del scatterplot están agrupados cerca de la recta de regresión creada. Como se observa a mayor número de habitaciones, mayor es el precio medio.

Si analizamos el porcentaje de personas de clase baja (`lstat`), se ve que hay otra correlación fuerte pero en este caso negativa. Analizando el diagrama de puntos, se confirma que a mayor precio medio, menor es el porcentaje de personas de clase baja. Sabemos que la correlación es fuerte ya que si nos fijamos, en la disposición de los puntos, podemos ver que descienden de forma ordenada cerca de la recta.

Tras visualizar el diagrama de puntos respecto a la proporción alumno-profesor (`ptratio`), la recta de regresión no consigue atrapar todos los puntos ya que la correlación entre las variables es débil. Sin embargo vemos que es negativa ya que a mayor precio, la proporción es menor.


Esto también ocurre cuando analizamos la distancia a centros de empleo (`dis`). La única diferencia es que en este caso, la correlación es positiva ya que a mayor precio medio, mayor es la distancia.

5) Análisis de los residuos:

Se pide mostrar en un *scatterplot* los residuos e_i (eje-x) y la predicción que hace la recta de regresión de la variable independiente LSTAT respecto a la variable MEDV con cada punto $\hat{y}_i$ (eje-y), también llamada variable ajustada. Se pide realizar un histograma de los residuos exclusivamente. Se pide investigar el significado y la importancia de este gráfico y comentarlo brevemente.

```
# CODIGO DEL ALUMNO
library(ggplot2)
modelo <- lm(medv ~ lstat, data = housing)
residuos <- modelo$residuals
frecuencia <- modelo$fitted.values


ggplot(data = data.frame(frecuencia, residuos),
       aes(x=residuos, y = frecuencia)) +
  geom_point() +
  labs(title = "Predicciones sobre Residuos")
```



```
ggplot(data = data.frame(residuos), aes(x=residuos)) +
  geom_histogram(color = "black", fill = "aquamarine") +
  labs(title = "Histograma de Residuos")
```

'stat_bin()' using 'bins = 30'. Pick better value with 'binwidth'.

Histograma de Residuos



Comentarios del alumno (máximo 100 palabras):

TEXTO DEL ALUMNO

Los residuos es como es un medida de como de bien se adaptan nuestro valores a la recta de regresión. Miden la distancia entre el valor actual y el valor en la recta. Como podemos ver tanto en el histograma, como en el scatterplot, los residuos aparecen mayoritariamente cerca del 0. En el scatterplot, los puntos se concentran cerca del $x = 0$ y en el histograma, la clase modal es $[-4, -2.5]$ que son valores no muy altos. Esto significa que nuestros valores se acoplan bien a la recta y que una regresion lineal se adapta correctamente para modelar la relación entre el % de personas de clase baja y el valor medio de la vivienda.

6) Regresión lineal múltiple:

Se pide realizar una regresión lineal múltiple con las dos variables independientes a la vez sobre la variable MEDV. Se pide, además, realizar un análisis de los residuos, similar al realizado en el apartado anterior.

CODIGO DEL ALUMNO


```
modeloMultiple <- lm (medv ~ lstat + rm, data = housing)

residuosMultiple <- modeloMultiple$residuals
frecuenciasMultiple <- modeloMultiple$fitted.values

ggplot(housing, aes(y = medv , x = lstat + rm)) +
```

```
geom_point(color = "turquoise") +
labs(title = "Precio Medio sobre Numero de Habitaciones y % de clase baja") +
geom_smooth(color = "red", se=FALSE)
```


```
## 'geom_smooth()' using method = 'loess' and formula = 'y ~ x'
```



```
ggplot(data = data.frame(frecuenciasMultiple,residuosMultiple),
  aes( x = residuosMultiple, y = frecuenciasMultiple)) +
geom_point() + geom_smooth(color = "red", se = FALSE) +
labs(title = "Predicciones sobre Residuos", x = "Residuos",
  y = "Frecuencia")
```

```
## 'geom_smooth()' using method = 'loess' and formula = 'y ~ x'
```



Predicciones sobre Residuos



```
ggplot(data = data.frame(residuosMultiple), aes(x = residuosMultiple)) +  
  geom_histogram(color = "black", fill = "aquamarine") +  
  labs(title = "Histograma de Residuos", x = "Residuos")
```

```
## 'stat_bin()' using 'bins = 30'. Pick better value with 'binwidth'.
```

Histograma de Residuos



Comentarios del alumno (máximo 150 palabras):

TEXTO DEL ALUMNO

Al ser una correlacion multiple, no tenemos una recta sino que los puntos siguen una curva. Parece que los puntos se asemejan muy bien a la curva de regresion asi que el coeficiente de regresión tiene que ser cercano a -1 ya que la regresion es negativa, es decir a menor valor medio, mayor es el valor del porcentaje de personas de clase baja y el numero de habitaciones.

Esto se nos confirma cuando analizamos el histograma y el scatterplot de los residuos. Vemos otra vez, que la clase modal de los residuos esta en -0.5 y -1.5 . Asi que los puntos suelen estar bastante cerca de la curva de regresion.