



Introducción a Ingeniería de Datos

Proyectos II: Tendencias de la Ingeniería del Software

Pablo Ramos Criado

Datos y su persistencia

- Dificultades históricas
 - Coste
 - Velocidad de acceso
 - Limitación capacidad



Datos y su persistencia

- Actualidad
 - Coste reducido
 - Tiempo de acceso reducido
 - Limitación capacidad prácticamente inexistente



Tipos de datos

- No estructurados
 - Documentos de lenguaje natural
 - Audios y videos

- Semi-estructurados
 - Páginas web
 - XML/JSON (pueden estar estructurados)

- Estructurados
 - Bases de datos

Tipos de datos

- No estructurados

- Necesitas procesos inteligentes para poder acceder a la información contenida.
 - Minería de datos y aprendizaje automático

- Estructurados

- La información es accesible de forma rápida a través de un sistema o método de consulta
 - Bases de datos y lenguajes de consulta

Bases de datos

- Bases de datos
 - Conjunto de datos pertenecientes a un mismo contexto y almacenados sistemáticamente para su posterior uso.
- Sistemas gestores de bases de datos (DBMS por sus siglas en inglés)
 - Sistema automatizado para el almacenamiento estructurado y posterior acceso de los datos.

Tipos de DBMS

- Librería

- No existe un servicio corriendo
- E.g.: SQLite

- Cliente – Servidor


- Existe un servicio encargado de la gestión de datos que es accedido a través de un cliente
- E.g.: MySQL, PostgreSQL, MongoDB, etc.

- Cliente – Servidor (Distribuido)

- El servidor está compuesto por un conjunto de máquinas
- E.g: Cassandra.

Sistemas distribuidos

- Almacenamiento masivo
- Acceso masivo
- Acceso concurrente
- Procesado en paralelo
- Tolerancia a fallos




Big Data

- A 1 de enero de 2021
 - 4.660 millones usan internet.
 - Cada día hay 875 mil nuevos usuarios
 - Cada usuario genera 1,7MB (1000 páginas) por segundo
- Desafíos del Big Data: Las 3V
 - Volumen
 - Variedad
 - Velocidad



Áreas del Big Data

- **Almacenamiento y Gestión de Datos**
- Procesamiento de Datos
- Análisis de Datos
- Privacidad y Seguridad de Datos
- Gobierno y Ética de Datos



Áreas del Big Data

- Almacenamiento y Gestión de Datos
- **Procesamiento de Datos**
- Análisis de Datos
- Privacidad y Seguridad de Datos
- Gobierno y Ética de Datos



Áreas del Big Data


- Almacenamiento y Gestión de Datos
- Procesamiento de Datos
- **Análisis de Datos**
- Privacidad y Seguridad de Datos
- Gobierno y Ética de Datos



Apache Pig


Áreas del Big Data

- Almacenamiento y Gestión de Datos
- Procesamiento de Datos
- Análisis de Datos
- **Privacidad y Seguridad de Datos**
- **Gobierno y Ética de Datos**




Arquitecturas Big Data

■ Arquitectura Lambda




■ Arquitectura Kappa





Arquitecturas Big Data

- Arquitectura Data Warehouse
- Arquitectura Data Lake & Data Lakehouse



Data Driven Decision Making


- Toma de decisiones respaldada por datos.



Business Intelligence vs Business Analytics

Análisis

- descriptivo
- diagnóstico



Análisis

- predictivo
- prescriptivo

Minería de datos

- Proceso por el cual se intenta desvelar patrones existentes en grandes volúmenes de conjuntos de datos a través de métodos / técnicas basadas en:
 - Estadística
 - Aprendizaje automático
 - Bases de datos

Minería de datos

■ Etapas

1. Definición del problema
2. Recopilación de datos
3. Limpieza de datos
4. Exploración de datos
5. Modelado y análisis
6. Evaluación y validación
7. Interpretación, aplicación y comunicación de resultados

Inteligencia Artificial (IA)

Pensar y actuar como un humano, pensar y actuar racionalmente.

(John McCarthy 1956)

(Algunas) áreas de la IA:

- Habla
- Visión
- Procesamiento del lenguaje natural
- Sistemas expertos
- Planificación y optimización
- Robótica
- **Aprendizaje automático**

Inteligencia Artificial (IA)

Thinking Humanly "The exciting new effort to make computers think ... <i>machines with minds</i>, in the full and literal sense." (Haugeland, 1985) "[The automation of] activities that we associate with human thinking, activities such as decision-making, problem solving, learning .. ." (Hellman, 1978)	Thinking Rationally "The study of mental faculties through the use of computational models." (Charniak and McDermott, 1985) "The study of the computations that make it possible to perceive, reason, and act." (Winston, 1992)
Acting Humanly "The art of creating machines that perform functions that require intelligence when performed by people." (Kurzweil, 1990) "The study of how to make computers do things at which, at the moment, people are better." (Rich and Knight, 1991)	Acting Rationally "Computational Intelligence is the study of the design of intelligent agents." (Poole <i>et al</i>, 1998) "AI ... is concerned with intelligent behavior in artifacts." (Nilsson, 1998)
Figure 1.1 Some definitions of artificial intelligence, organized into four categories.	

Inteligencia Artificial (IA)

Inteligencia artificial simbólica VS sub-simbólica

- **Simbólica:** métodos de inteligencia artificial con representación de alto nivel simbólico del conocimiento o problema (**fácil interpretación**).
 - e.g. Sistemas expertos (reglas *if.-then*)
- **Sub-simbólica:** métodos de inteligencia artificial sin representación específica del conocimiento o problema (**difícil interpretación**).
 - e.g. Soft-computing
- **Combinaciones de las anteriores**
 - e.g. Agentes inteligentes y sistemas multi-agente

Inteligencia Artificial (IA)

Soft-computing: existen problemas que no se pueden resolver con certeza y soluciones aproximadas son suficientes:

- Redes de neuronas artificiales
 - Inspirados en los sistemas nerviosos.
- Computación evolutiva
 - Inspirados en la teoría de la evolución.
- Sistemas basados en lógica difusa
 - Conjuntos con límites difusos.

Inteligencia Artificial (IA)

Evolución


1. IA clasificadora
2. IA generativa
3. IA interactiva

Aprendizaje automático (ML)


Área de la IA que tiene como objetivo crear sistemas capaces de **aprender por ellos mismos** a partir de un conjunto de **datos o experiencia**, sin ser programados de forma explícita.

Objetivo:


- Análisis **predictivo**:
 - Anticiparnos a acontecimientos
- Análisis **prescriptivo**:
 - Tomar decisiones a partir de un estado




ML: Software 1.0




ML: Software 1.0: Ejemplo




ML: Software 2.0




ML: Software 2.0: Ejemplo



ML: Modelo



ML: Modelo



Nuevo paradigma

Preparados para el nuevo paradigma de desarrollo software:

- **Software 1.0:** Análisis del problema y diseño y desarrollo de la solución paso a paso.
 - Necesario rediseñar el software ante cambios.
 - Funcionamiento conocido.
- **Software 2.0:** Análisis de los datos del problema y la solución esperada. La solución se obtiene mediante optimización del modelo ML.
 - Adaptable y mejorable ante cambios.
 - Puede desconocerse la totalidad del funcionamiento.
 - Coste computacional constante y por lo general bajo o controlable.

Minería de datos

- Ciclo de vida general
 - Selección y preparación de datos
 - **Entrenamiento:** Selección y ejecución del algoritmo que creará el modelo
 - **Producción:** Uso y mantenimiento (mejora) del modelo

Minería de datos

■ Etapas

1. Definición del problema
2. Recopilación de datos
3. Limpieza de datos
4. Exploración de datos
5. Modelado y análisis
6. Evaluación y validación
7. Interpretación, aplicación y comunicación de resultados

Aprendizaje Automático (ML)

Tipos de aprendizaje automático

- Aprendizaje supervisado
- Aprendizaje no supervisado
- Aprendizaje semi-supervisado
- Aprendizaje por refuerzo


ML: Aprendizaje supervisado

El conjunto de datos utilizado para entrenar el modelo **está etiquetado**. Se conoce el valor a predecir para cada observación recopilada.

- A partir de un conjunto de **datos de entrada observados** X el modelo es capaz de **predecir/estimar** un/os **dato/s de salida** y

¿Lloverá?

$y = \text{Sí}$



ML: Aprendizaje supervisado


Regresión

- A partir de un conjunto de entradas X se intenta predecir/estimar el valor de una variable de salida y con infinitos posibles valores.
 - $y \in \mathbb{R}$
 - $y \in \mathbb{N}$

$$\hat{y} = h_{\Theta}(X) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

$$h_{\Theta}(X) = X\Theta^T$$


$$h_{\Theta}(X) \approx y$$



ML: Aprendizaje supervisado

Clasificación

- A partir de un conjunto de entradas X se intenta predecir/estimar el valor de una variable de salida y con finitos posibles valores.
 - $y \in \{C_1, C_2, \dots, C_l\}$



$$\hat{y} = h_{\Theta}(X) = g(X\Theta^T)$$

$$h_{\Theta}(X) \approx y$$

ML: Aprendizaje supervisado

Métodos paramétricos vs no paramétricos

■ Paramétricos

- Se define previamente un **conjunto de parámetros** para optimizar.
- El modelo es más **sencillo de entrenar**.
- Si el problema no puede ser modelado con esos parámetros, el modelo no lo resolverá.

■ No paramétricos

- No existe ningún (o casi) tipo de asunción inicial.
- Útil en problemas **sin conocimiento previo**.
- El modelo es más **lento de entrenar y necesita más datos**.

ML: Aprendizaje supervisado

Conjunto de datos

- Entrenamiento

- Se utiliza para entrenar/optimizar los **parámetros** del modelo

- Validación

- Se utiliza para entrenar/optimizar los **hiperparámetros** del modelo



- Test

- Se utiliza para obtener la **bondad/precisión** del modelo.
 - Debe estar oculto todo el proceso de entrenamiento (incluso en preparación de datos) para obtener la bondad del modelo en un entorno similar al de producción.

ML: Aprendizaje supervisado

Sobreaprendizaje

- Fenómeno por el cual un modelo se ajusta en exceso al conjunto de datos de entrenamiento reduciendo su rendimiento en producción.



ML: Aprendizaje supervisado

Rendimiento

- Necesidad de fijar un **valor de referencia** como objetivo.
 - Utilizar medidas de precisión específicas.
 - Un error nulo, e_0 , no es **realista**.
 - Intentar conseguir un error nulo puede producir problemas de **sobreaprendizaje**.
- **Error óptimo de Bayes** e_{BO} (Clasificación)
 - **Valor de referencia óptimo**.
 - Mejor error posible para cualquier sistema de aprendizaje automático.
- Nivel de **error humano** e_{HL} (Persona o consenso)
 - Aproximación al error óptimo de Bayes
 - Utilizado sobre todo en reconocimiento de imágenes y audio, y procesamiento del lenguaje natural (NLP).
 - Para este tipo de problemas $e_{HL} \approx e_{BO}$

ML: Aprendizaje supervisado

¿Qué tipo de error tenemos?

Error	Tipo de error	
e_0		
Diferencia error	Sesgo	Sesgo no evitable
$e_{HL} \approx e_{BO}$		
Diferencia error		Sesgo evitable
e_{train}		
Diferencia error		Varianza
e_{val}		

ML: Aprendizaje supervisado

¡No tengo suficientes datos!

- Solución: Utilizar recursos externos para obtener un conjunto de datos suficientemente grande.
 - Train/val o train/dev.

Error	Tipo de error	
e_0		
Diferencia error		Sesgo no evitable
$e_{HL} \approx e_{BO}$	Sesgo	
Diferencia error		Sesgo evitable
e_{train}		
Diferencia error		Varianza
$e_{train/val}$		
Diferencia error		Datos train no representativos
e_{val}		

ML: Aprendizaje no supervisado

El conjunto de datos utilizado por el modelo **no está etiquetado**.

- A partir de un conjunto de **datos de entrada observados** X el modelo es capaz **extraer patrones o relaciones entre datos** para poder etiquetarlos, ordenarlos o agruparlos.



ML: Aprendizaje no supervisado

El conjunto de datos utilizado por el modelo **no está etiquetado**.

- A partir de un conjunto de **datos de entrada observados** X el modelo es capaz **extraer patrones o relaciones entre datos** para poder etiquetarlos, ordenarlos o agruparlos.



ML: Aprendizaje no supervisado

Métodos de **partición**

- Se crean particiones sucesivas del conjunto de datos
 - Número de particiones fijo.

Métodos **jerárquicos**

- Se descompone jerárquicamente el conjunto de datos

Métodos basados en **densidad**

- Se utilizan funciones de densidad y conectividad para estudiar la interrelación.

ML: Aprendizaje semi-supervisado

Útil en entornos con **pocos datos etiquetados**.

- Se combina el uso de datos etiquetados con datos no etiquetados.
 - Datos no etiquetados:
 - Gran cantidad de datos.
 - **Extraer patrones y características principales** del problema a resolver.
 - Datos etiquetados
 - Conjunto de datos limitado e **insuficiente para entrenar un modelo** por si solo.
 - Entrenar el modelo partiendo del conocimiento extraído de los datos no etiquetados.

ML: Aprendizaje por refuerzo


Método de aprendizaje automático **sin conocimiento previo**.

- La generación de conocimiento es dirigido por medio de **recompensas**

- Psicología conductivista:

- Acción adecuada → recompensa positiva
- Acción inapropiada → recompensa negativa

- Objetivo:** Búsqueda del conjunto de acciones en relación al entorno que **maximice la recompensa a corto y largo plazo**.



Aprendizaje Automático (ML)

Tipos de aprendizaje automático

- Aprendizaje supervisado
- Aprendizaje no supervisado
- Aprendizaje semi-supervisado
- Aprendizaje por refuerzo