




Big Data Stack

Proyectos II: Tendencias de la Ingeniería del Software

Pablo Ramos Criado


Big Data Stack | Hadoop Stack



Big Data Stack | Hadoop Stack


- **Hadoop** es una plataforma de código libre para el almacenamiento y procesamiento distribuido de grandes volúmenes de información en clústeres de cientos de nodos.
 - **HDFS (Hadoop Distributed File System)** para **almacenamiento** de información. Basado en *Google File System*.
 - **MapReduce** para el **procesado**. Basado en MapReduce de Google
- Además de estas dos herramientas, implementa otras utilidades que:
 - Trabajan sobre *MapReduce*
 - Trabajan sobre *HDFS*

Big Data Stack | Hadoop Stack




HDFS: Hadoop Distributed File System

- Para mejor manejo de los datos y mejorar la integridad de los datos, dividimos el archivo en sub-bloques.



HDFS: Hadoop Distributed File System

- 3 réplicas de cada bloque.



HDFS: Hadoop Distributed File System

- HDFS tiene una **arquitectura maestro/esclavo**.
 - Un cluster HDFS está compuesto por:
 - Un *NameNode* que administra el acceso al sistema de archivos. Por lo general existe un *NameNode* activo y otro en modo de espera por si el primero falla.
 - Un conjunto *DataNodes* (tantos como nodos tiene el cluster) que administran el almacenamiento de datos.
 - El sistema de archivos HDFS permite almacenar archivos de todo tipo. HDFS divide los archivos en sub-bloques de un tamaño predefinido (64MB) y los distribuye en los *DataNodes* según el factor de replicación.

Map Reduce

- **MapReduce** es una técnica de **procesado en paralelo** de grandes cantidades de información en **clústeres**.
 - Está basado en las funciones de programación funcional *map* y *reduce*.
 - No obstante, el verdadero potencial de esta técnica surge del uso en **paralelo** de estas funciones. La ejecución en un solo hilo de esta técnica no ofrecería ninguna ventaja sustancial.
 - Esta técnica solo es eficiente para procesar **grandes cantidades de información**. Para conjuntos de datos pequeños es más eficiente la ejecución secuencial.


Hadoop: Tres pasos

- **Map:** Realiza tareas de filtrado y ordenamiento de datos.
 - Cada nodo que almacena parte de la información a procesar, ejecuta una tarea *map* sobre sus datos y guarda el resultado temporalmente.
- **Shuffle & Sort:** Reorganiza los resultados.
 - Los resultados son reorganizados para que los resultados pertenecientes a una misma clave se encuentren localizados físicamente en un mismo nodo.
- **Reduce:** Realiza tareas de agregación de datos.
 - Los resultados agrupados de una misma clave son procesados por una tarea reduce que obtiene el resultado final para esa clave.


Map Reduce: Proces

Televisor	Electrónica	450€
Batidora	Cocina	60€
...	...	...
Balón	Deportes	15€


put




Map Reduce: Proces




Map Reduce: Proces



Map Reduce: Proces



Map Reduce: Proces



Big Data Stack | Hadoop Stack

